Федеральное государственное бюджетное образовательное учреждение высшего образования
«Сибирский государственный университет телекоммуникаций и информатики»
(СибГУТИ)

Институт информатики и вычислительной техники

09.03.01 "Информатика и вычислительная техника"
профиль "Программное обеспечение средств
вычислительной техники и автоматизированных систем"

Кафедра прикладной математики и кибернетики

Теория информации

Практическая работа №2

Побуквенное кодирование текстов.

Выполнил:

студент гр.ИП-213
Дмитриев Антон Александрович
ФИО студента

«__» _____ 2026 г.

Проверил:

Преподаватель

ФИО преподавателя

«__» _____ 2026 г. Оценка_____

Новосибирск 2026 г.

1. Задание

1. Запрограммировать процедуру двоичного кодирования текстового файла побуквенным кодом. В качестве методов сжатия использовать метод Хаффмана и метод Шеннона (или метод Фано). Текстовые файлы использовать те же, что и в практической работе 1.

2. Вычислить среднюю длину кодовых слов и оценить избыточность кодирования для каждого построенного побуквенного кода.

3. После кодирования текстового файла вычислить оценки энтропии файла с закодированным текстом H_1, H_2, H_3 (после кодирования последовательность содержит 0 и 1) и заполнить таблицу. Избыточность кодирования определяется как $r = L_{cp} - H$, где H – предельная энтропия текста, $L_{\text{ср}}$ – средняя длина кодовых слов.

4. Оформить отчет, загрузить отчет в электронную среду. Отчет обязательно должен содержать заполненную таблицу и анализ полученных результатов.

2. Результаты

Результаты кодирования

Метод	Файл	Избыточность	H1 бит	H2 бит	H3 бит
Хаффман	file1.txt	0.0001	1.0000	0.9999	0.9999
Шеннон-Фано	file1.txt	0.0001	1.0000	0.9999	0.9999
Хаффман	file2.txt	0.0081	0.9991	0.9987	0.9981
Шеннон-Фано	file2.txt	0.0081	0.9995	0.9990	0.9983
Хаффман	file3.txt	0.0273	0.9959	0.9959	0.9955
Шеннон-Фано	file3.txt	0.0284	0.9998	0.9997	0.9994

3. Анализ результатов

1. Сравнение методов по избыточности

- Для файлов с простым распределением вероятностей (равномерным и заданным вручную) оба метода показывают одинаковую эффективность. Это объясняется тем, что распределения позволяют построить оптимальное разбиение и в методе Шеннона-Фано.
- Для реального текста на русском языке (file3.txt) метод Хаффмана даёт меньшую избыточность (0.0273 против 0.0284), что подтверждает его теоретическое преимущество — **гарантированную оптимальность**. Разница небольшая (около 4%), но устойчивая.

2. Анализ энтропии закодированных последовательностей

file1.txt (равномерное распределение)

- $H_1 \approx 1.0000$ бит
- $H_2 \approx 0.9999$ бит
- $H_3 \approx 0.9999$ бит

Интерпретация: битовая последовательность практически максимально случайна (энтропия близка к 1), корреляции между соседними битами отсутствуют. Это идеальный случай для кода Хаффмана.

file2.txt (неравномерное независимое распределение)

- H_1: 0.9991–0.9995 бит
- H_2: 0.9987–0.9990 бит
- H_3: немного ниже

Интерпретация: энтропия битового потока также близка к 1, но наблюдается небольшое убывание H_2 и H_3 по сравнению с H_1. Это связано с тем, что кодовые слова имеют разную длину, что создаёт слабые корреляции между битами на границах слов.

file3.txt (русский текст)

- Хаффман: $H_1 = 0.9959$, $H_2 = 0.9959$, $H_3 = 0.9955$
- Шеннон-Фано: $H_1 = 0.9998$, $H_2 = 0.9997$, $H_3 = 0.9994$

Интерпретация:

- Для метода Шеннона-Фано энтропия битового потока выше (ближе к 1), чем для Хаффмана. Это парадоксально, так как избыточность у Шеннона-Фано больше.
- Объяснение: более высокая энтропия битового потока не означает лучшего сжатия. Она лишь говорит о том, что биты в закодированной последовательности более равновероятны и независимы. Однако средняя длина кодового слова при этом может быть больше, что и даёт большую избыточность.
- Для Хаффмана H_1 немного ниже (0.9959 против 0.9998), но при этом средняя длина кода меньше — сжатие эффективнее.