Федеральное государственное бюджетное образовательное учреждение высшего образования
«Сибирский государственный университет телекоммуникаций и информатики»
(СибГУТИ)

Институт информатики и вычислительной техники

09.03.01 "Информатика и вычислительная техника"
профиль "Программное обеспечение средств
вычислительной техники и автоматизированных систем"

Кафедра прикладной математики и кибернетики

Теория информации

Практическая работа №1

Вычисление энтропии Шеннона.

Выполнил:

студент гр.ИП-213
Дмитриев Антон Александрович
ФИО студента

«__» _____ 2026 г.

Проверил:

Преподаватель

ФИО преподавателя

«__» _____ 2026 г. Оценка_____

Новосибирск 2026 г.

1. Задание

1. Для выполнения работы потребуются три текстовых файла с различными свойствами. Объем файлов больше 10 Кб, формат txt.

В первом файле содержится последовательность символов, количество различных символов больше 2 (3,4 или 5). Символы **последовательно и независимо** с равными вероятностями генерируются с помощью датчика псевдослучайных чисел и записываются в файл.

Для генерации второго файла необходимо сначала задать набор вероятностей символов (количество символов такое же, как и в первом файле), а затем **последовательно и независимо** генерировать символы с соответствующей вероятностью и записывать их в файл, вероятности в процессе записи файла не меняются.

В качестве третьего файла необходимо выбрать художественный текст на русском (английском) языке. Для алфавита текста предполагается, что строчные и заглавные символы не отличаются, знаки препинания опущены, к алфавиту добавлен пробел, для русских текстов буквы «е» и «ё», «ь» и «ъ» совпадают.

2. Составить программу, определяющую несколько оценок энтропии созданных текстовых файлов. Вычисление значения по формуле Шеннона **настоятельно рекомендуется** оформить в виде отдельной функции, на вход которой подается массив (список) вероятностей символов, выходной параметр – значение, вычисленное по формуле Шеннона.

Вычислить три оценки энтропии Шеннона для каждого из файлов. Рекомендуется вычисление оценки оформить в виде отдельной функции с параметром имя файла:

Первая оценка H_1. Сначала определить частоты отдельных символов файла, т.е. отношения количества отдельного символа к общему количеству символов в файле. Далее используя полученные частоты как оценки вероятностей, рассчитать оценку энтропии по формуле Шеннона.

Вторая оценка H_2. Определить частоты всех последовательных пар символов в файле. Для того правильной оценки энтропии H_2 пары символов нужно рассматривать с перехлестом.

Пример. Пусть имеется такая последовательность ФЫВАФПРО

Под парами понимаются пары соседних символов, т.е.

ФЫ ЫВ ВА АФ ФП ПР РО

Для подсчета оценки энтропии H_2 необходимо подсчитать частоту каждой пары символов и подставить в формулу Шеннона. Полученное значение оценки энтропии следует разделить на 2.

Третья оценка H_3. Определить частоты всех последовательных троек символов в файле. Для того правильной оценки энтропии H_3 **тройки** символов нужно рассматривать с перехлестом.

Для подсчета оценки энтропии H_3 необходимо подсчитать частоту каждой тройки символов и подставить в формулу Шеннона. Полученное значение оценки энтропии следует разделить на 3.

По желанию можно продолжить процесс вычисления оценок с использованием частот четверок, пятерок символов и т.д.

3. После тестирования программы необходимо заполнить таблицу для отчета и в отчете **проанализировать** полученные результаты, объяснить замеченные эффекты. Для получения теоретических значений энтропии использовать наборы вероятностей, которые использовались при генерации файлов, для файла с текстом на естественном языке не заполнять.

2. Результаты

```
==============================================================================
Оценки энтропии (в битах на символ)
==============================================================================
Файл            H₁          H₂          H₃          Max         Теоретическая
------------------------------------------------------------------------------
file1.txt       1.9999      1.9998      1.9992      2.0000      2.0000
file2.txt       1.7459      1.7458      1.7454      2.0000      1.7427
file3.txt       4.4915      4.0064      3.4448      5.0444      ---
```

3. Анализ результатов

1. Каким образом реализована генерация файлов?

Файл 1 (file1.txt) создан с использованием генератора псевдослучайных чисел. Символы выбираются независимо и равновероятно из алфавита, состоящего из 4 символов (например, {A, B, C, D}). Объём файла составляет 20 000 символов.

Файл 2 (file2.txt) генерируется из того же алфавита, но с заданным неравномерным распределением вероятностей (например, [0.5, 0.25, 0.15, 0.1]). Символы также независимы. Для обеспечения воспроизводимости результатов используется фиксированное начальное значение (random.seed(42)).

Файл 3 (file3.txt) представляет собой художественный текст на русском языке, прошедший предобработку: приведение к нижнему регистру, замена «ё» на «е», «ъ» на «ь», удаление всех символов, кроме русских букв и пробелов (с сохранением пробела как значимого элемента). Объём текста достаточен для статистического анализа (более 10 КБ).

2. Соотношение оценок для каждого файла

Для file1.txt: оценки H_1, H_2 и H_3, практически равны (различия менее 0,001 бита) и совпадают с теоретическим значением 2,0000 бита. Это объясняется тем, что символы генерируются независимо и равновероятно — энтропия на символ не зависит от длины блока. Небольшие отклонения обусловлены конечным объёмом выборки.

Для file2.txt: также наблюдается близость всех трёх оценок друг к другу (отклонения порядка 0,0005 бита) и к теоретической энтропии 1,7427 бита. Причина та же — независимость символов, хотя распределение неравномерно.

Для file3.txt: оценки заметно различаются: H_1 = 4,4915 бита, H_2 = 4,0064 бита, H_3 = 3,4448 бита. Убывание значений при переходе к блокам большей длины

отражает наличие статистических связей между соседними символами в естественном языке (корреляции букв и типичные сочетания).

3. Прогноз поведения последовательности оценок при увеличении длины блока
Если продолжить вычислять энтропию для блоков длины n (H_n), то для стационарного эргодического источника последовательность будет убывать (не возрастать) и стремиться к некоторому пределу — истинной энтропии источника. Для независимых символов (файлы 1 и 2) все H_n теоретически равны, поэтому последовательность остаётся постоянной. Для текста на естественном языке (файл 3) с ростом n H_n будет уменьшаться, приближаясь к величине, характеризующей неопределённость с учётом всех долговременных зависимостей.

4. Значения энтропии Шеннона для файлов
Файл 1: истинная энтропия равна теоретическому значению 2,0000 бита/символ (равномерное распределение).

Файл 2: истинная энтропия равна заданному распределению — 1,7427 бита/символ.

Файл 3: точное значение энтропии неизвестно, но по полученным оценкам можно предположить, что она лежит ниже H_3 = 3,4448 бита. С учётом убывания при увеличении длины блока наиболее вероятное значение находится в интервале 2,8–3,2 бита/символ (типичная оценка для литературного русского текста).